




Embedded AI를 활용한 실시간 다중 모달리티 디커플링

Bio-Robotics and Control (BiRC) Lab
Department of Mechanical Engineering
Korea University

HeeJun Moon


0. 연구 주제

Time Division Measurement (TDM)




- 시분할 측정 방식을 통해 단일 센서에 순차적으로 AC excitation, DC excitation, No excitation을 반복하여 인가
- 각 상태에서 센서의 공진주파수, 저항, 전압(TENG)을 각각 독립적으로 측정

Modality Decoupling



- 시분할 측정 방식으로 얻은 독립적인 물리량들을 학습모델로 디커플링하여 다중 모달(인장, 압력, 근접도, 물체의 전기적 성질, 촉감) 센싱

0. Previous Work




Part 1


Setup & Preparation

Sensor Fabrication
PCB Circuit Design
Software Development
Custom Test Platform Setup

완료




1. eGaIn 평면 코일 유연 센서 제작



2. TDM PCB 회로 설계 및 알고리즘 개발

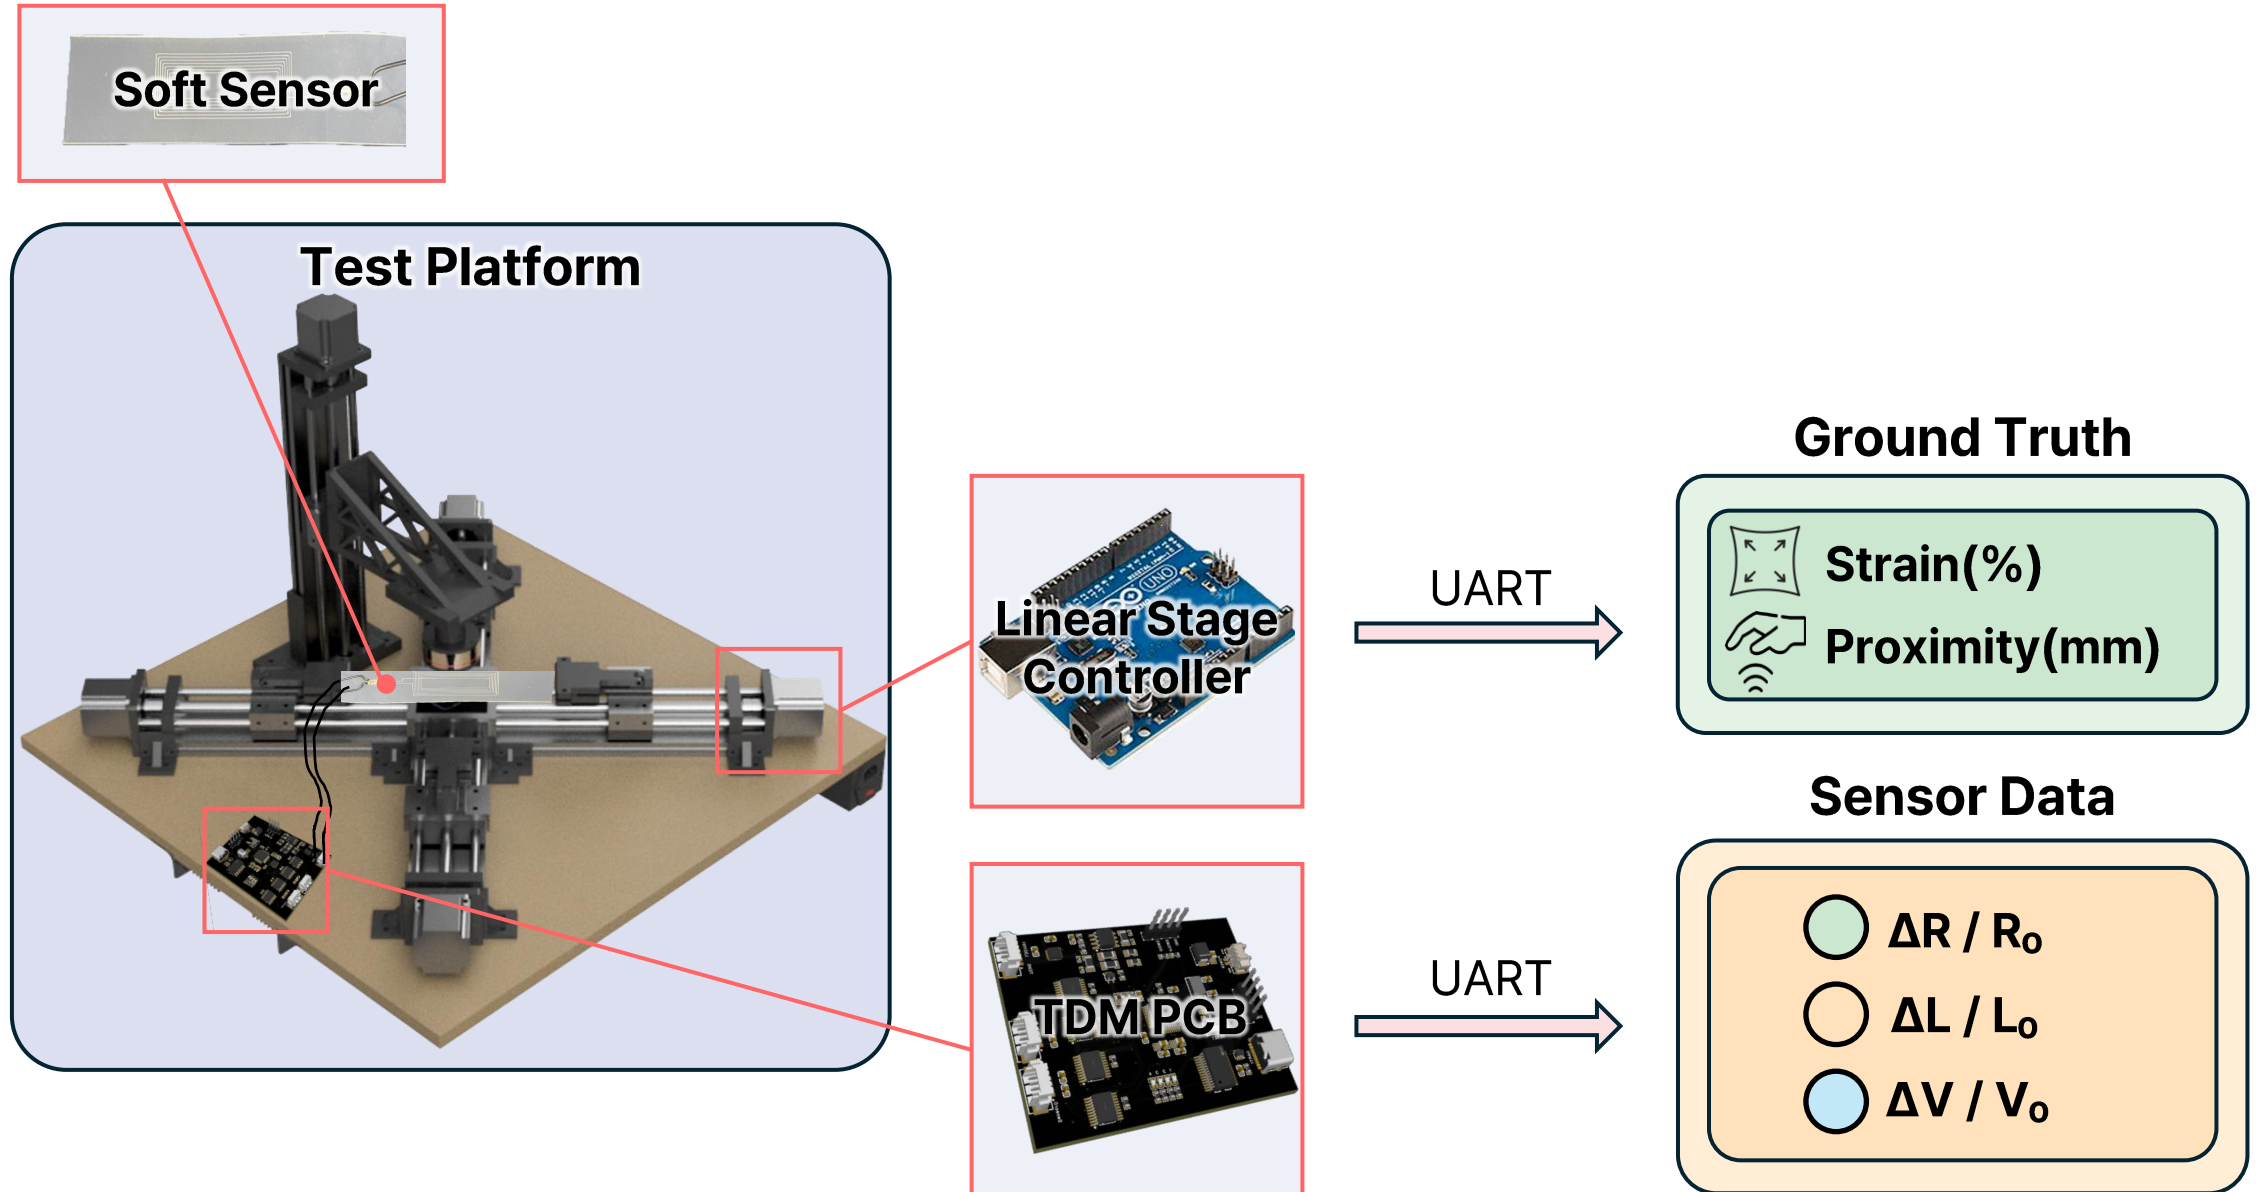
*Time Division Measurement



3. 인장, 근접, 접촉 제어가 가능한 5축 linear stage 제작

1. Strain-Proximity Decoupling


0. 실험 세팅



1. 데이터 수집

- 인장 & 근접도

- 1. Strain: Discrete / Proximity: Continuous



- 총 샘플 : 100,353
- 기간 : 1004s
- Sampling Rates: 100Hz
- Strain : 0→30% (24step 단조 증가)
- Proximity : 36→1mm (연속 감소)

- 2. Strain: Continuous / Proximity: Discrete




- 총 샘플 : 87,879
- 기간 : 880s
- Sampling Rates: 100Hz
- Strain : 0→30% (연속 증가)
- Proximity : 36→1mm (24step 단조 감소)


1. 데이터 수집

- Time Series Graph

- 1. Strain: Discrete / Proximity: Continuous




- 2. Strain: Continuous / Proximity: Discrete




1. 데이터 수집

- 3D Plot


Resistance



Inductance




Inductance + Resistance




- 2D Heatmap & Contour


Resistance



Inductance




Contour



2. 학습 및 검증

- DNN 모델


- Single DNN



Parameter	49,592
MACs(Multiply-Accumulate)	49,140
Test MAE ϵ (%)	0.346
Test MAE d (mm)	1.827

*MAE(Mean Absolute Error): 평균 절대 오차

- Two-Stage DNN




Parameter	50,306
MACs(Multiply-Accumulate)	49,664
Test MAE ϵ (%)	0.343
Test MAE d (mm)	1.783


2. 학습 및 검증

- 학습 결과

Strain



Proximity





- 오차율

	Strain	Proximity
MAE	0.3435%	1.783mm
RMSE	0.4319%	2.772mm
R^2	0.9974	0.9298
Max Error	1.823%	13.459mm

3. 실시간 추론

- PC-based Realtime Decoupling



3. 실시간 추론

- PC-based Realtime Decoupling 오차

MAE

모달리티	구간	학습 추론 오차	PC 실시간 추론 오차
Strain(ϵ)	전체	0.3435%	0.208%
Proximity(d)	전체	1.783mm	1.438mm
	$d \leq 15mm$		0.145mm
	$d \leq 10mm$		0.096mm

RMSE

모달리티	구간	학습 추론 오차	PC 실시간 추론 오차
Strain(ϵ)	전체	0.4319%	0.272%
Proximity(d)	전체	2.772mm	2.273mm
	$d \leq 15mm$		0.203mm
	$d \leq 10mm$		0.133mm

4. EI Embedding

- Embedded AI (Edge AI)란?


Embedded AI

기기 내부에서 인공지능을 실행하는 기술

- 정의
 - 센서 데이터를 기기(임베디드 시스템) 내부에서 AI 모델이 직접 처리하고 판단/제어까지 수행하는 기술
- 핵심 특징
 - 실시간 처리 : 데이터가 기기 내부에서 즉시 처리되어 지연 최소화
 - 독립성 : 클라우드 연결 없이도 동작 (네트워크 불필요)
 - 보안 & 프라이버시 : 데이터 외부 전송 없이 안전하게 처리
 - 저전력 설계 : 경량 모델과 하드웨어 가속기로 효율적인 연산 수행
- 구성 요소
 - 센서/입력 → 임베디드 프로세서(NPU/MCU/SoC) → AI 모델(Inference) → 의사결정/제어 출력
- 활용 분야
 - 로봇, 스마트 센서, 드론, 자율주행, 산업 IoT, 웨어러블, 스마트 헬스케어 등
- 장점
 - 빠른 응답 속도, 네트워크 의존성 감소, 비용 절감, 데이터 보안 강화, 오프라인 환경에서도 안정적 동작

Embedded AI는 제한된 자원(Power, Memory, 연산 능력) 환경에서 최적화된 모델과 하드웨어로 지능적인 판단을 수행하는 기술입니다.

Embedded AI 동작 흐름




Embedded AI의 장점



데이터가 생성되는 현장에서 즉시 지능적인 판단을 수행하여 더 빠르고, 안전하고, 효율적인 시스템을 구현합니다.

4. EI Embedding

- 배포 파이프라인



- 모델 파라미터 최적화 → 메모리 사용량, 연산량, 추론속도 개선

- Flash: 112KB → 978B
- MACs: 50,306 → 892
- 연산속도: 1068.78us → 141.01us

- 임베딩 최적화

- 1. 컴파일러 최적화

- Og → 57KB

- 2. X-CUBE-AI 런타임

- SMLAD DSP, Word Packing



- 3. 모델 양자화

- 50,306파라미터 Flash 196KB->52KB
 - 양자화 오차 → eps-MAE: 0.061%, d-MAE: 0.070mm

S1 구조	S2 구조	파라미터	INT8 FLASH	MACS	MAE ε (%)	MAE D (mm)	MAE D≤15 (mm)
1→4→1	2→8→1	46	46 B	32	0.3810	2.1149	0.8058
1→8→1	2→16→1	90	90 B	64	0.3630	2.1102	0.7810
1→8→1	2→32→1	154	154 B	112	0.3680	1.9779	0.5610
1→4→4→1	2→8→8→1	138	138 B	112	0.3518	1.8368	0.3943
1→16→1	2→16→8→1	242	242 B	200	0.3514	1.8016	0.3476
1→16→8→1	2→16→8→1	370	370 B	320	0.3493	1.7978	0.3463
1→16→8→1	2→32→16→1	818	818 B	744	0.3491	1.7822	0.3217
1→8→1	2→32→16→1	666	666 B	608	0.3496	1.7850	0.3258
1→16→8→1	2→64→32→1	2,482	2.4 KB	2,360	0.3491	1.7813	0.3165
1→32→16→1	2→64→32→1	2,914	2.8 KB	2,768	0.3519	1.7792	0.3118
1→16→8→4→1	2→32→16→8→1	978	978 B	892	0.3515	1.7651	0.3222
1→16→8→1	2→128→64→1	8,882	8.7 KB	8,664	0.3497	1.7735	0.3177
1→64→32→1	2→128→64→1	10,946	10.7 KB	10,656	0.3490	1.7730	0.3133
1→128→128→6 4→1	2→128→128→6 4→1	50,306	52KB	49,664	0.3435	1.7830	0.3009

4. EI Embedding

- EI-based Realtime Decoupling



4. EI Embedding

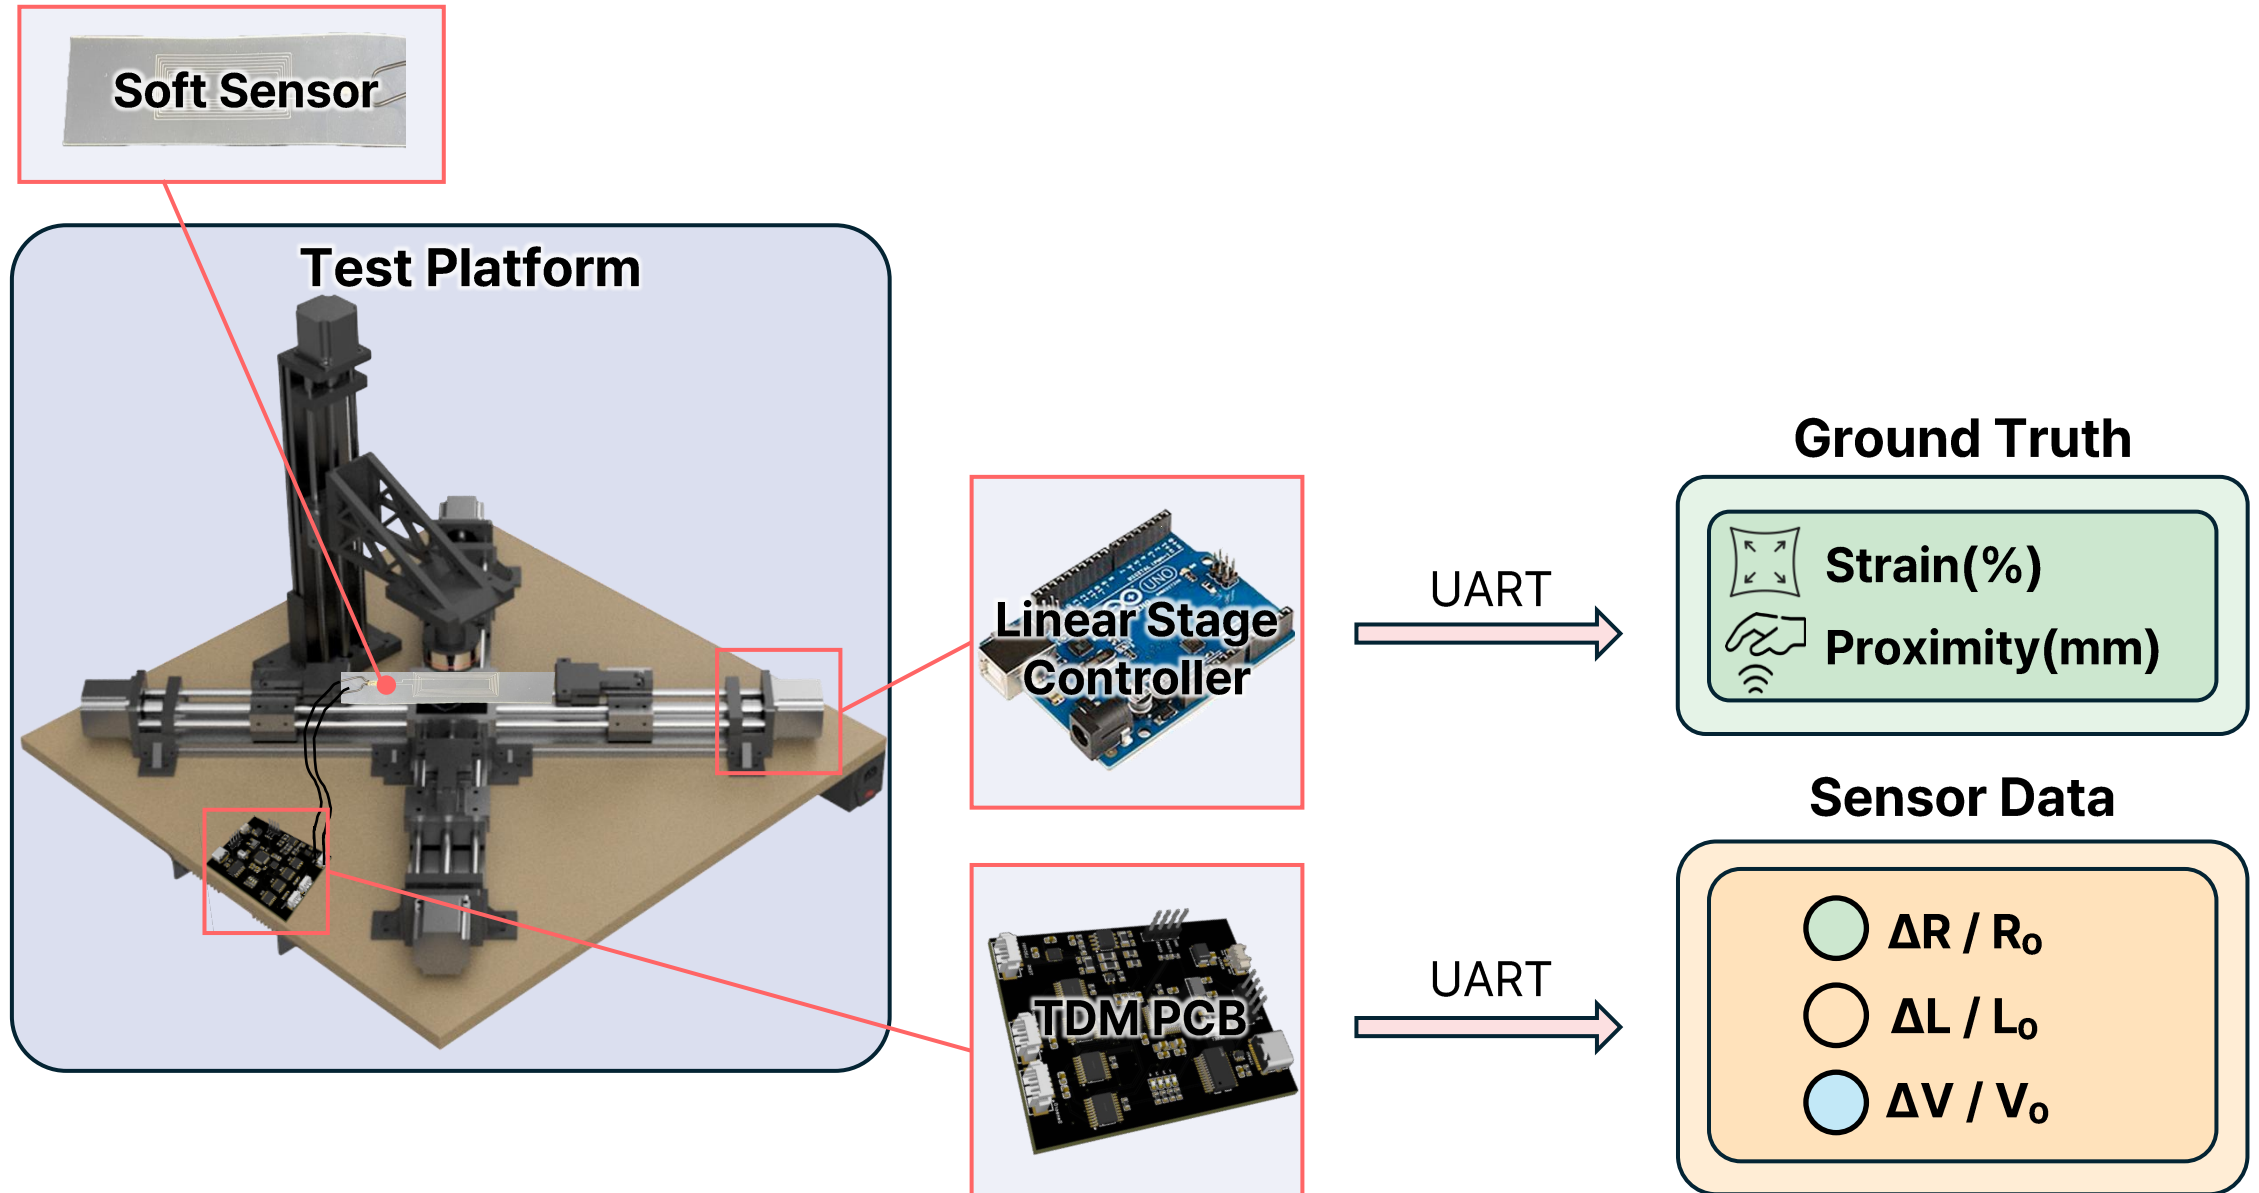
- EI-based Realtime Decoupling 오차

MAE				
모달리티	구간	학습 추론 오차	PC 실시간 추론 오차	EI 실시간 추론 오차
Strain(ϵ)	전체	0.3435%	0.208%	0.422%
Proximity(d)	전체	1.783mm	1.438mm	2.281mm
	$d \leq 15mm$		0.145mm	0.867mm
	$d \leq 10mm$		0.096mm	0.669mm

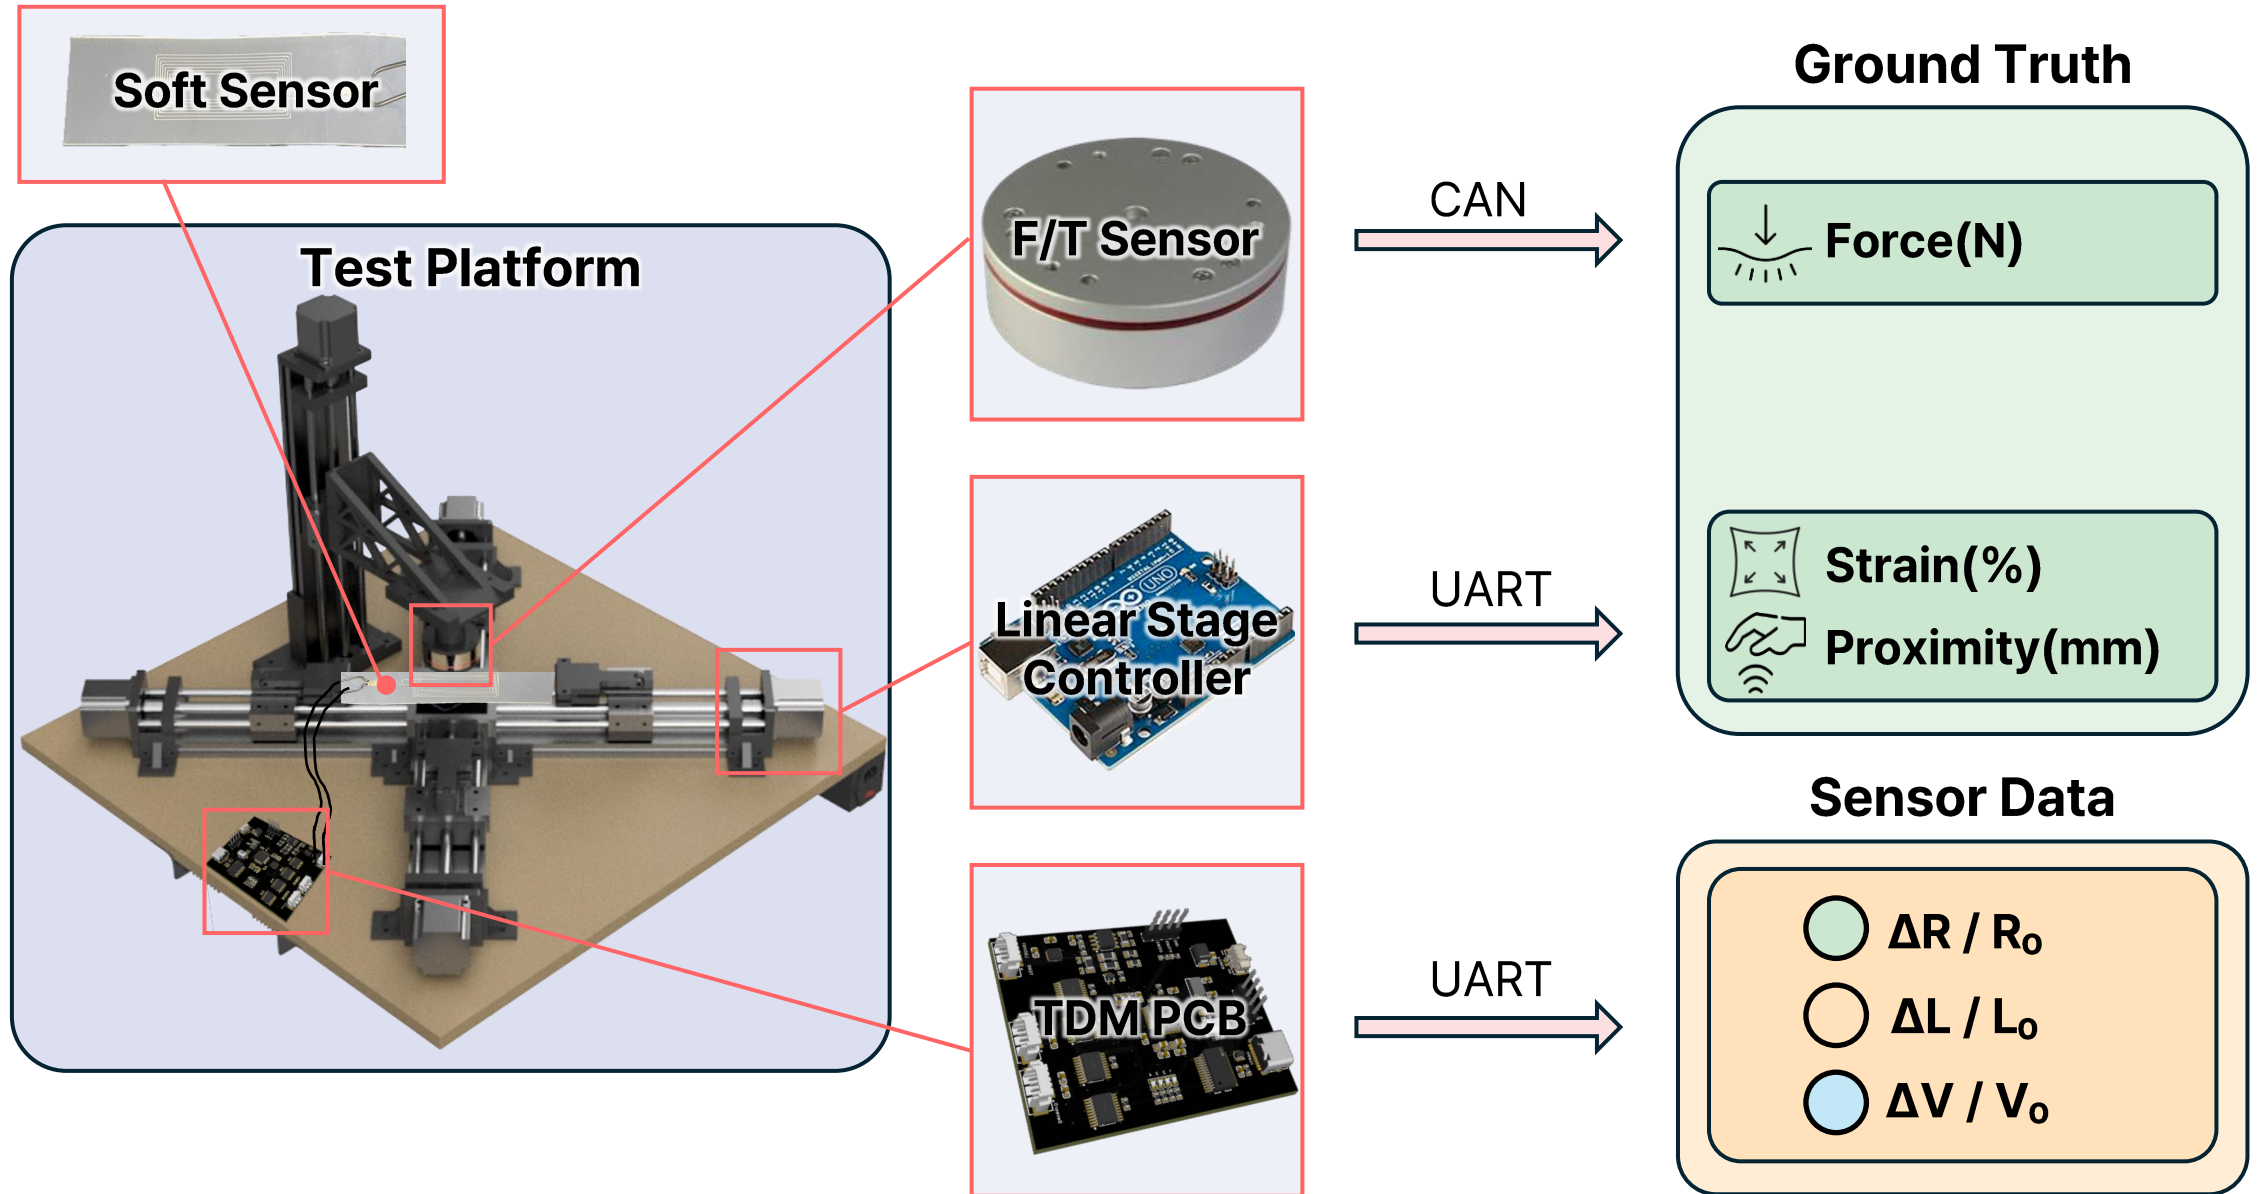
RMSE				
모달리티	구간	학습 추론 오차	PC 실시간 추론 오차	EI 실시간 추론 오차
Strain(ϵ)	전체	0.4319%	0.272%	0.519%
Proximity(d)	전체	2.772mm	2.273mm	3.971mm
	$d \leq 15mm$		0.203mm	1.040mm
	$d \leq 10mm$		0.133mm	0.724mm

2. Pressure Modal Decoupling 추가

0. 실험 세팅 - F/T 센서 추가






0. 실험 세팅 - F/T 센서 추가



0. 센서 구조 변경

- 돌기구조 추가



- 센서 압력 민감도를 높이기 위해 돌기 구조 추가
- 필름 마스킹, 어플리케이터를 이용하여 균일한 직경(5mm) 및 높이(0.5mm)의 돌기구조 제작


1. 데이터셋 취득

1. Strain(discrete)


- 0mm(0%) → 36mm(30%) : 총 19 steps (2mm 간격)

2. Position(continuous)

- 근접 + 압력
- 근접: 25mm ~ 0mm
- 압력: 0mm ~ -1.2mm (0N~9N)





▲ 실측 동영상 (8 배속)





1. 데이터셋 취득

- 3D Plot



접촉 구간



전체 구간





비접촉 구간



1. 데이터셋 취득

- 인덕턴스가 왜 증가하는가?



- * **Quality-factor**

$$Q = \omega * \frac{\text{Maximum Stored Energy}}{\text{Energy Dissipated per Cycle}} = \frac{X}{R_s} = \frac{\omega L}{R_s}$$

- 센서 압축 시에, L 감소, R_{DC} , R_{eddy} 증가 → Q-factor 급감

- * **인덕턴스 측정방법**

- 실제 공진주파수: $f = \frac{1}{2\pi\sqrt{LC}} \times \sqrt{1 - \frac{1}{Q^2}}$


- 근사 공진주파수: $f \approx \frac{1}{2\pi\sqrt{LC}}$ → 인덕턴스 계산: $\frac{\Delta L}{L_0} = \frac{f_0^2}{f^2} - 1$

- 압축 시에는 Q 가 작아지면서 실제 공진주파수 감소 → L 을 근사 공진주파수로 역산하는 과정에서 L 이 증가하는 것처럼 보임

DNN으로 디커플링 → Q 역산 보정 필요X

2. 학습 및 검증

- 학습 모델




2. 학습 및 검증

SLS-EMA

- 표준선형고체(Standard Linear Solid, SLS) 모델


- 크리프와 히스테리시스를 예측할 수 있는 점탄성 모델



- 미분 방정식 : $\sigma + \frac{\eta}{E_1 + E_2} \dot{\sigma} = \frac{E_1 E_2}{E_1 + E_2} \varepsilon + \frac{E_1 \eta}{E_1 + E_2} \dot{\varepsilon}$
- Creep 해 : $\varepsilon(t) = \frac{\sigma_0}{E_1} + \frac{\sigma_0}{E_2} (1 - e^{-\frac{E_2}{\eta} t})$
- 시간상수 : $\tau_c = \frac{\eta}{E_2} \rightarrow$ 데이터 기반 fitting $\tau = 1.01s$

- 지수이동평균(EMA, Exponential Moving Average)

- 시계열 데이터 분석에서 최신 데이터에 더 높은 가중치를 부여하고 과거 데이터로 갈수록 가중치가 지수적으로 감소하도록 계산하는 이동 평균 기법



- $weight(\Delta t) = e^{-\frac{\Delta t}{\tau}}$


- $EMA(t) = \frac{\sum [x(t-\Delta t) \times weight(\Delta t)]}{\sum [weight(\Delta t)]}$, $(x_1(t) = \frac{\Delta L}{L_0}(t), x_2(t) = \frac{\Delta R}{R_0}(t))$

< 재귀식(Recursive Formula) > → 임베디드용 간단한 연산

$$EMA_n = EMA_{n-1} + \alpha(x_n - EMA_{n-1}) \quad , (\alpha = 1 - e^{-\frac{\Delta t_{sample}}{\tau}})$$

2. 학습 및 검증


Gate-MOE (Mixture of Experts)



- 게이트로 현재 접촉 상태를 구별한 후, 각 상태에 맞는 전문 모델을 적용




2. 학습 및 검증

- SLS-EMA + Gate-MOE (Mixture of Experts) 모델



2. 학습 및 검증

- 디커플링 결과




모델	게이트 정확도	Strain R ²	Strain RMSE	Proximity R ²	Proximity RMSE	Force R ²	Force RMSE
Gate-MOE SLS-EMA 모델	1.000	0.999	0.108%p	0.999	0.318mm	0.995	0.253N


2. 학습 및 검증

• 모델 성능 검증


Model A : Gate-MOE + SLS-EMA 모델




Model B : Gate-MOE X + SLS-EMA 모델



Model C : Gate-MOE + SLS-EMA X 모델



Model D : Gate-MOE + GRU 모델



2. 학습 및 검증

• 모델 성능 검증

모델	구조	입력 피쳐 수	레이어 구조	활성함수	출력	파라미터	총 파라미터
<Model A> Gate-MOE SLS-EMA 모델	게이트	4	4→8→4→1	tanh, tanh, sigmoid	접촉확률(0~1)	81	1,429
	전문가 A (근접)	4	4→24→16→8→2	tanh×3, linear	strain(%), 거리(mm)	674	
	전문가 B(압력)	4	4→24→16→8→2	tanh×3, linear	strain(%), 힘(N)	674	
<Model B> Gate-MOE X SLS-EMA	통합모델	4	4→32→24→16→8→2	tanh×4, linear	strain(%), 거리/힘(mm)	1,506	1,506
<Model C> Gate-MOE SLS-EMA X	게이트	2	2→8→4→1	tanh, tanh, sigmoid	접촉확률(0~1)	65	1,317
	전문가 A(근접)	2	2→24→16→8→2	tanh×3, linear	strain(%), 거리(mm)	626	
	전문가 B(압력)	2	2→24→16→8→2	tanh×3, linear	strain(%), 힘(N)	626	
<Model D> Gate-MOE GRU 모델	게이트	4	4→8→4→1	tanh, tanh, sigmoid	접촉확률(0~1)	81	1,061
	전문가 A(근접)	4	4→24→16→8→2	tanh×3, linear	strain(%), 거리(mm)	674	
	전문가 B(압력) GRU	2	GRU(2→8, 1층) + Linear(8→2)	GRU 내부 게이트(σ , tanh), 출력 linear	strain(%), 힘(N)	306	

2. 학습 및 검증


- 모델 성능 검증

모델	게이트 정확도	Strain R ²	Strain RMSE	Proximity R ²	Proximity RMSE	Force R ²	Force RMSE	총 파라미터
<Model A> Gate-MOE SLS-EMA 모델	1.000	0.999	0.108%p	0.999	0.318mm	0.995	0.253N	1,429
<Model B> Gate-MOE X SLS-EMA	-	0.998	0.288%p	0.999	0.322mm	0.963	0.079mm	1,506
<Model C> Gate-MOE SLS-EMA X	0.982	0.999	0.194%p	0.998	0.410mm	0.981	0.521N	1,317
<Model D> Gate-MOE GRU 모델	1.000	0.999	0.123%p	0.999	0.318mm	0.995	0.263N	1,061

* FT Sensor 노이즈: ±0.19N

3. EI Embedding


- EI-based Realtime Decoupling



3. EI Embedding


- EI-based Realtime Decoupling

구간 1. Strain 고정




Strain R ²	Strain RMSE	Proximity R ²	Proximity RMSE	Force R ²	Force RMSE
0.970	1.690%p	0.867	3.276mm	0.777	1.798

구간 2. Proximity 고정



Strain R ²	Strain RMSE	Proximity R ²	Proximity RMSE	Force R ²	Force RMSE
0.600	6.742%p	-0.096	6.088mm	-	-

구간 3. 동시 변화



Strain R ²	Strain RMSE	Proximity R ²	Proximity RMSE	Force R ²	Force RMSE
0.602	6.265%p	-2.051	10.397mm	-	-

Future Work



감사합니다

Bio-Robotics and Control (BiRC) Lab
Department of Mechanical Engineering
Korea University

HeeJun Moon